

Redes Convolucionales

Conectividad Local



Principios Básicos

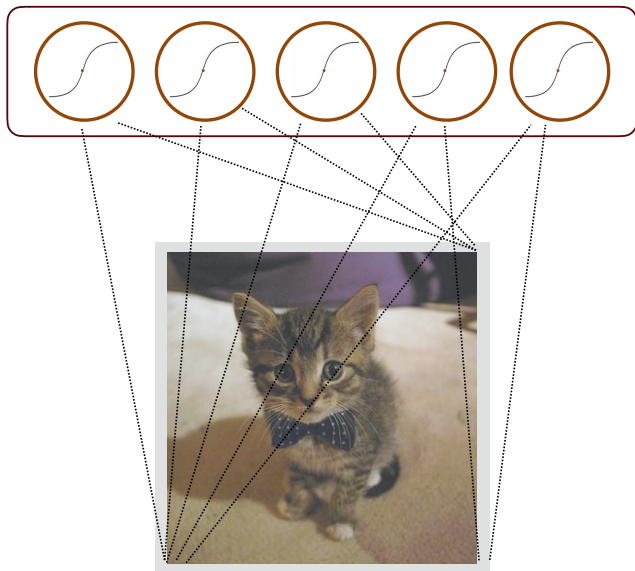
- Las capas de una red convolucional serán capaces de **patrones locales en grandes arreglos multi-dimensionales de datos**. Esto se logrará mediante 3 principios básicos de diseño:



- **Conectividad local.**
 - Compartición de pesos.
 - Pooling.
- A esto sumaremos un principio transversal de diseño: mantener la topología de los datos a medida que se propaga por la red.

Conectividad Local


- Las neuronas de un MLP tradicional tienen una conectividad innecesariamente alta si sabemos que los patrones por reconocer en los datos de entrada *son locales*.



- Campo receptivo:** restringir a **vecindad** de cada neurona para que vea sólo un subconjunto de unidades *adyacentes* del dato de entrada. De este modo la neurona sólo podrá detectar patrones presentes en ese subconjunto de unidades.


Campo Receptivo 1D

- El principio de localidad se implementará respetando la topología del patrón de entrada. Si se trata de arreglos uni-dimensionales de datos, las vecindades serán 1D.




Campo Receptivo 1D

- En este caso, **cada neurona ve sólo S_i posiciones del patrón de entrada.** Los campos receptivos de unidades adyacentes se desplazan de acuerdo un parámetro K_i denominado **stride**.



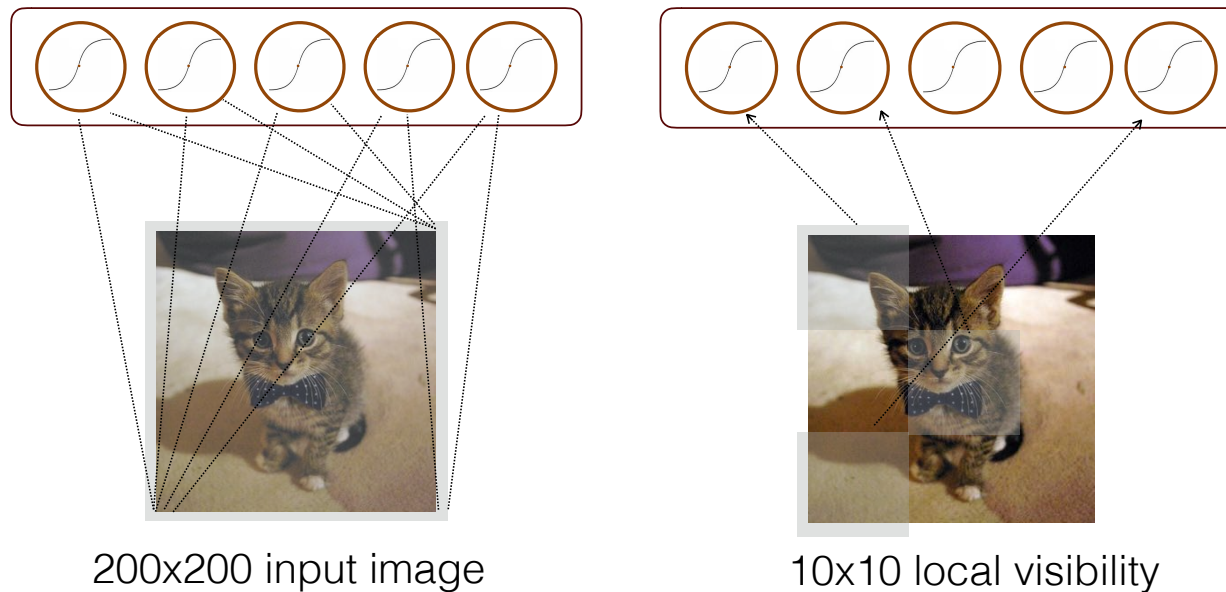
Campo Receptivo 1D

- En este caso, **cada neurona ve sólo S_i posiciones del patrón de entrada.** Los campos receptivos de unidades adyacentes se desplazan de acuerdo un parámetro K_i denominado **stride**.



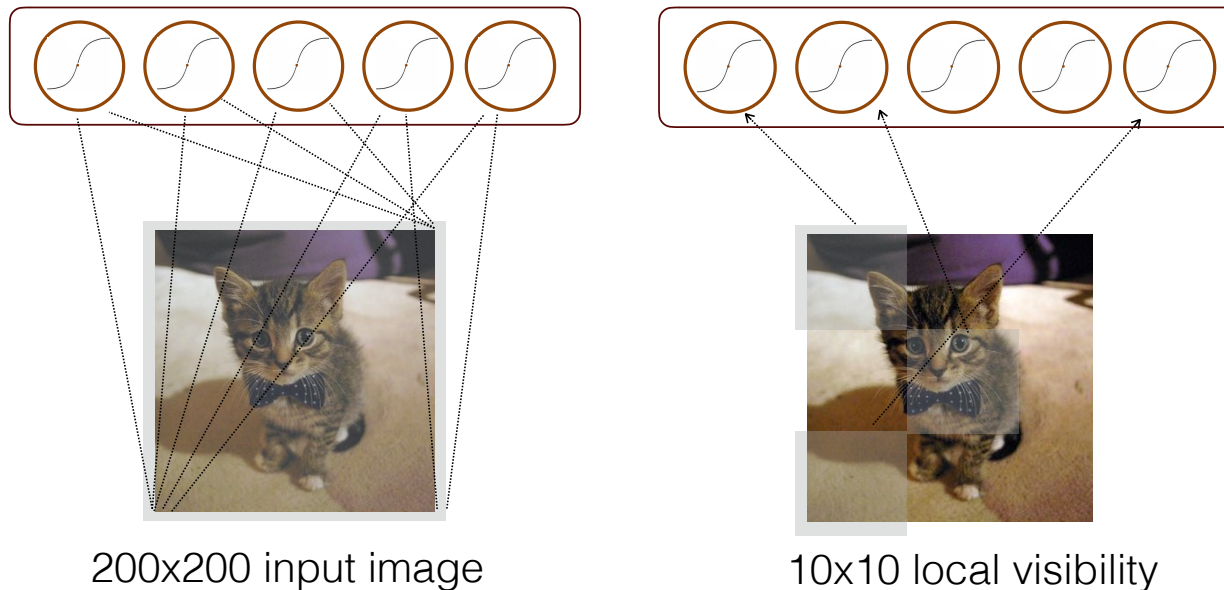
Campo Receptivo 2D

- Si la capa procesa arreglos bi-dimensionales de datos, las vecindades debiesen ser 2D.



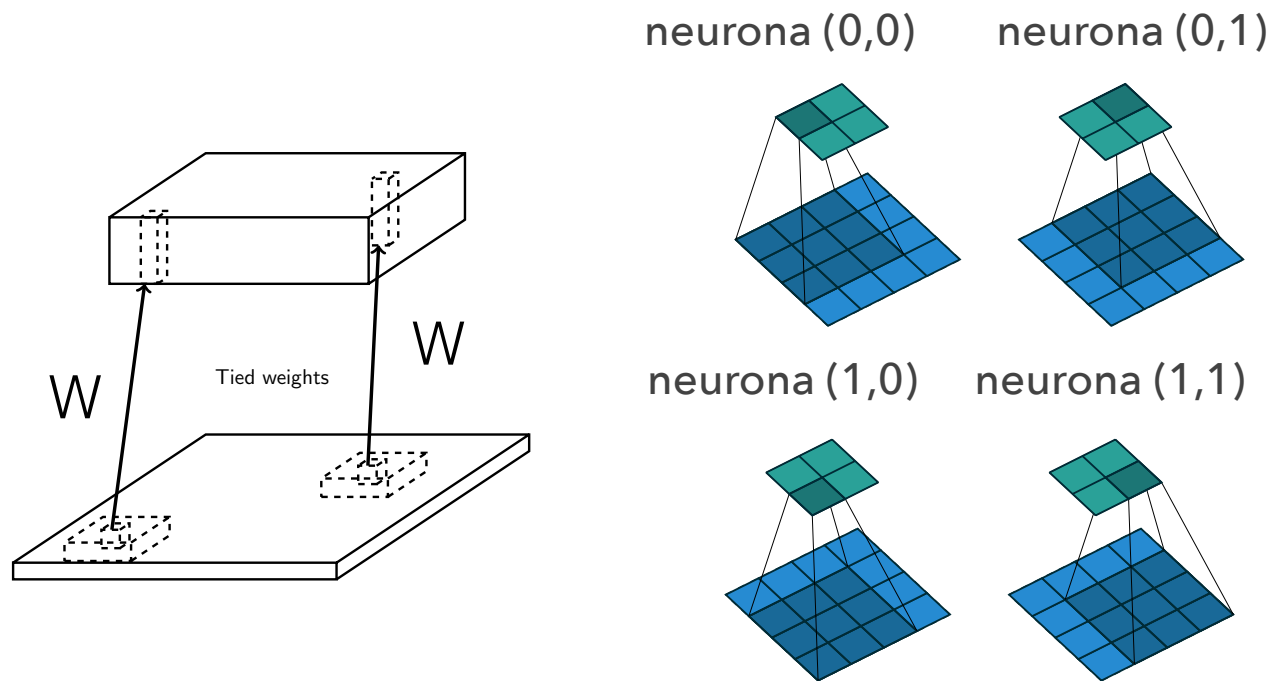
Campo Receptivo 2D

- En este caso, **cada neurona ve una región de tamaño $S_i \times S_j$ sobre el patrón de entrada** y los campos receptivos de unidades adyacentes se desplazan de K_i unidades en la primera dimensión y K_j unidades en la segunda dimensión. Los valores K_i y K_j se denominan **strides**.



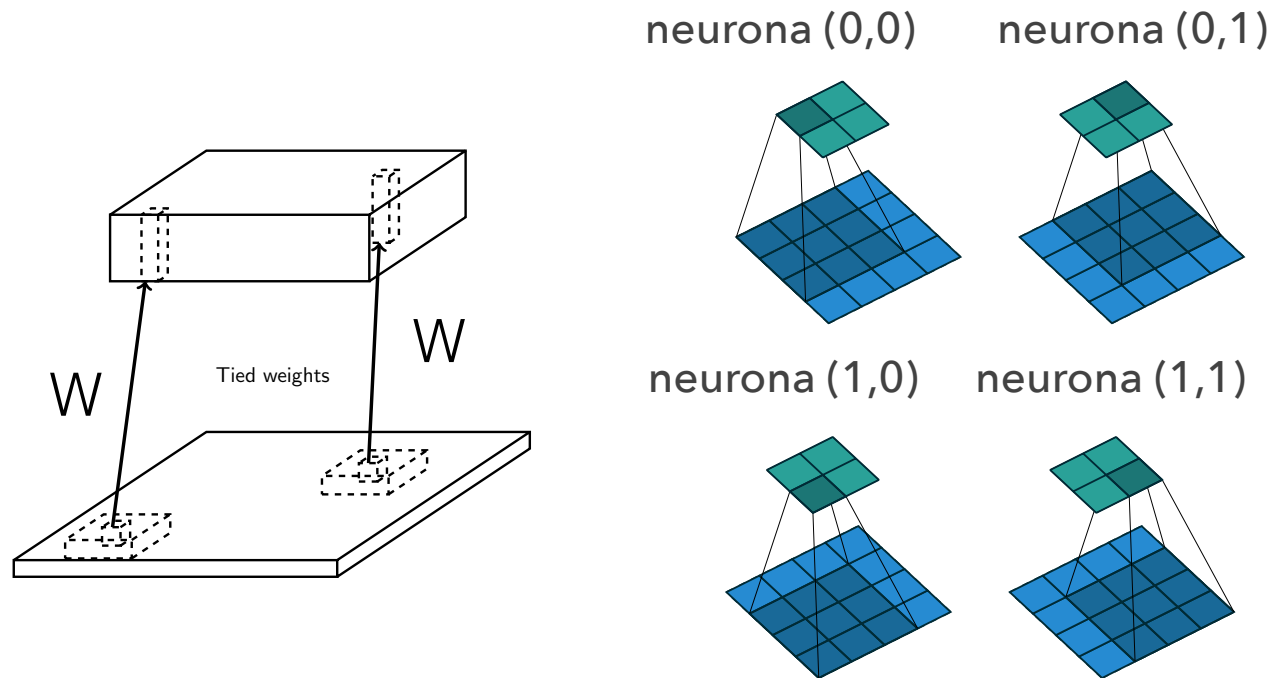
Campo Receptivo 2D

- De hecho, para poder iterar esta idea en profundidad, **las neuronas de una capa que procesa arreglos bi-dimensionales, se debiese organizar en forma de un arreglo bi-dimensional.**



Campo Receptivo 2D


- Esta idea simplifica también la definición los campos receptivos.



- Campo de la neurona (i,j): $[K_i \cdot i, K_i \cdot i + S_i) \times [K_j \cdot j, K_j \cdot j + S_j)$


Campo Receptivo 3D

- Si se trata de arreglos tri-dimensionales de datos, las vecindades debiesen ser 3D.




Ejercicio (Ahorro de Parámetros)

- Si la imagen entrante es de $200 \times 200 \times 3$ y definimos campos receptivos de 10×10 ¿cuántos parámetros ahorramos respecto a una capa densa (completamente conectada)?



$200 \times 200 \times 3$ input image



10×10 local visibility

Entonces ...

- Una red convolucional (CNN) se construye sobre 3 ideas fundamentales: conectividad limitada, compartición de pesos y agresiva reducción de dimensionalidad vía pooling.
- La conectividad local permite un gran ahorro de parámetros respecto a una capa densa e induce la preferencia del modelo por patrones locales en los datos de entrada (e.g. patrones espaciales, patrones temporales, etc).
- Patrones más amplios se pueden detectar apilando capas convolucionales en profundidad.
- Los parámetros más importantes para definir la conectividad local son: la dimensión de la capa, el tamaño de los campos receptivos y el stride.

