

# Redes Convolucionales

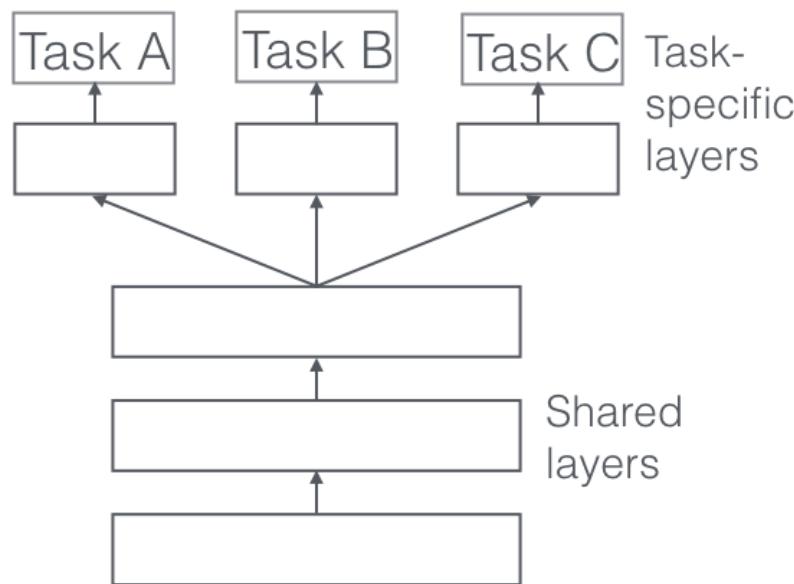
Compartición de Pesos



Prof. Ricardo Ñanculef - Departamento de Informática UTFSM 2022

# Compartición de Pesos

- Es interesante verificar que esta idea se ha manifestado de variadas formas en la literatura, encontrando su expresión más “formal” en el problema denominado *multi-task learning*.



Rich Caruana (1997). Multitask learning. *Machine learning*, 28(1), 41-75.



# Principios Básicos de una CNN

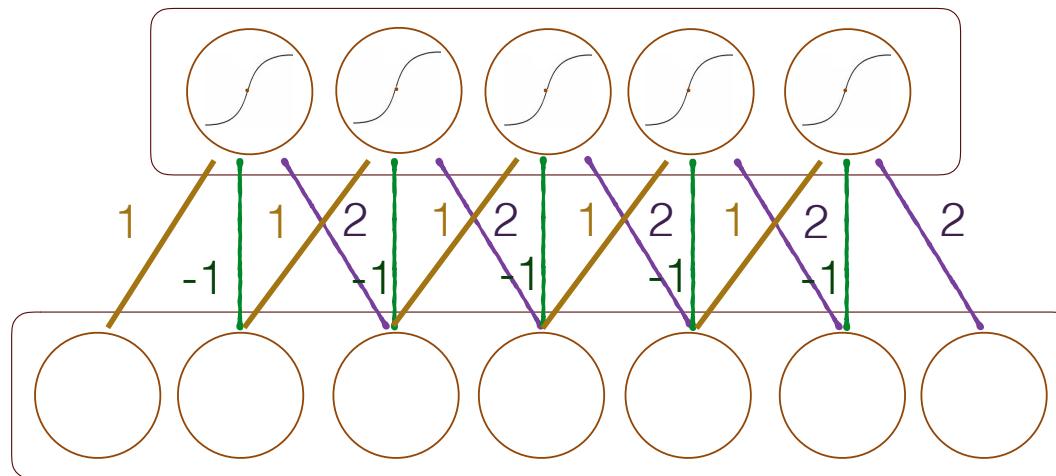
- Las capas de una red convolucional serán capaces de **patrones locales en grandes arreglos multi-dimensionales de datos.** Esto se logrará mediante 3 principios básicos de diseño:



- **Conectividad local.**
  - Compartición de pesos.
  - Pooling.
- A esto sumaremos un principio transversal de diseño: mantener la topología de los datos a medida que se propaga por la red.

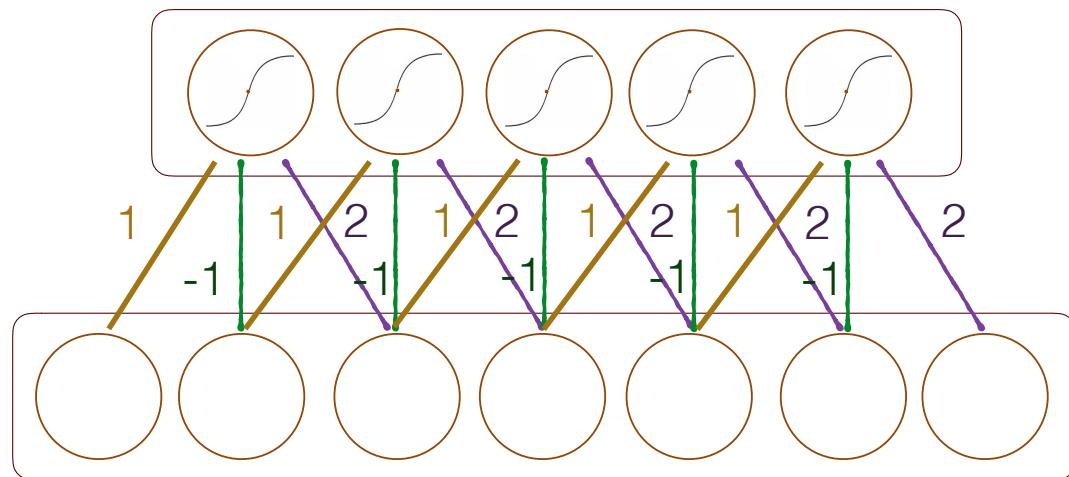
# Compartición de Pesos

- Una forma de limitar el número de parámetros de a red, sin podar excesivamente la conectividad, es forzar a un grupo de unidades a **compartir los pesos** es decir agregar al problema de optimización la restricción de que éstos deben ser idénticos.



# Canales o Filtros

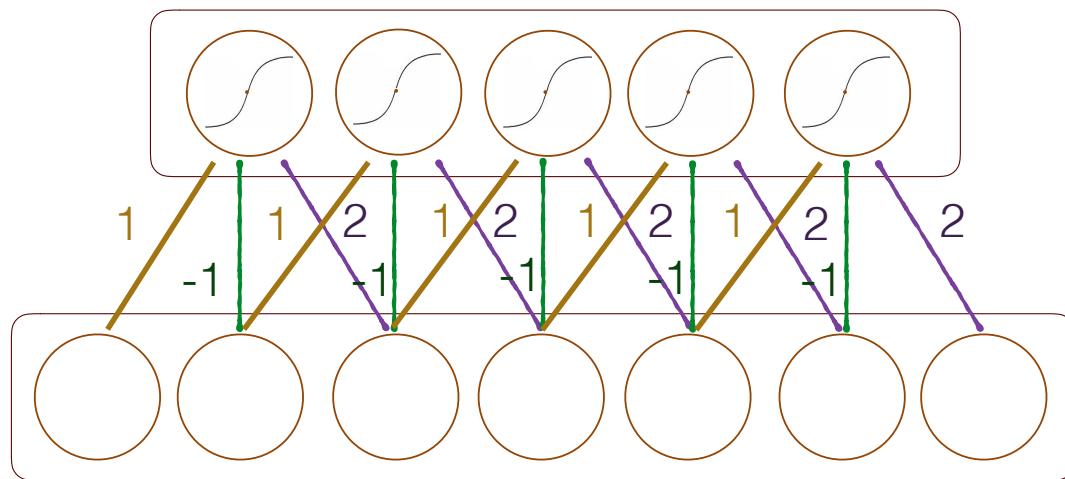
- Compartir pesos nos permitirá definir **grupos de neuronas con campos visuales muy similares entre sí** (stride pequeño, por ejemplo 1). Estas neuronas trabajarán en conjunto para detectar un determinado patrón en diferentes posiciones del volumen entrante.



- Nos referiremos a un grupo como **un canal** o **un filtro**.

# Mapas de Características (Feature Maps)

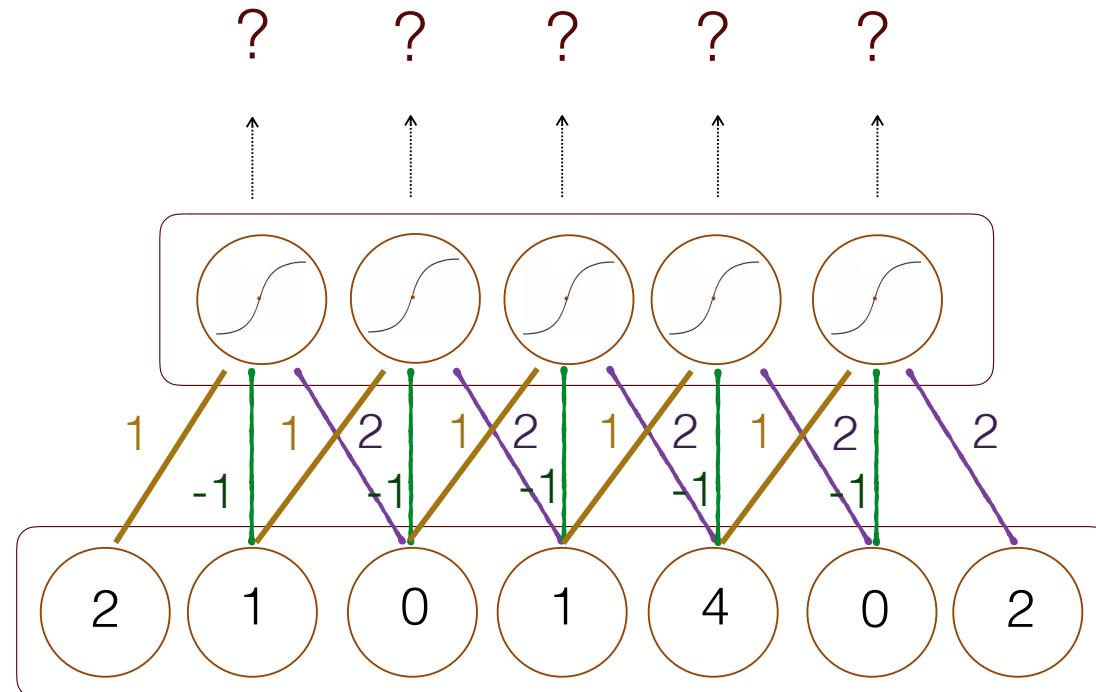
- El número de neuronas del FM se determinará para poder cubrir completamente el patrón de entrada considerando el stride y el tamaño del campo receptivo de canal.



- La activación de este grupo de neuronas se denominará **mapa de características (feature map, FM)**. A veces se llama también FM al grupo de unidades en sí mismo.

# Mapas de Características (Feature Maps)

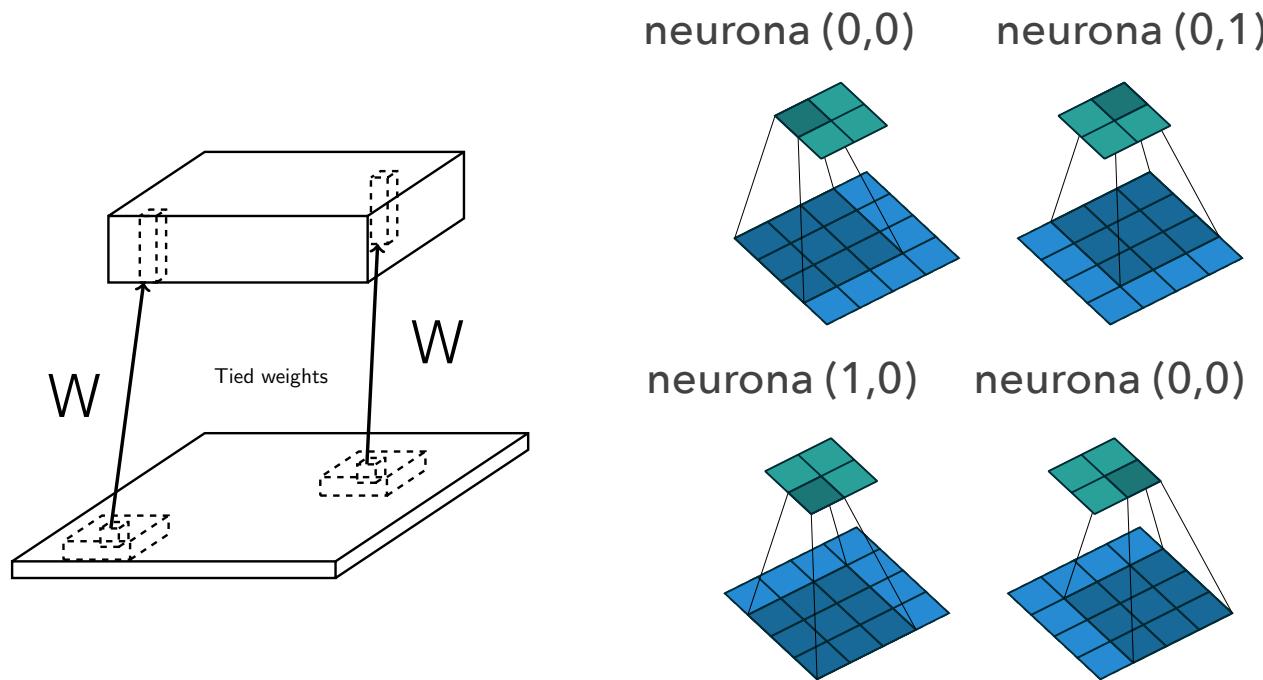
- Claramente, aún si el grupo de unidades comparte pesos, su activación sobre el mismo patrón de entrada no es igual.



(\*) Asuma umbrales de activación 0 y funciones de activación lineales.

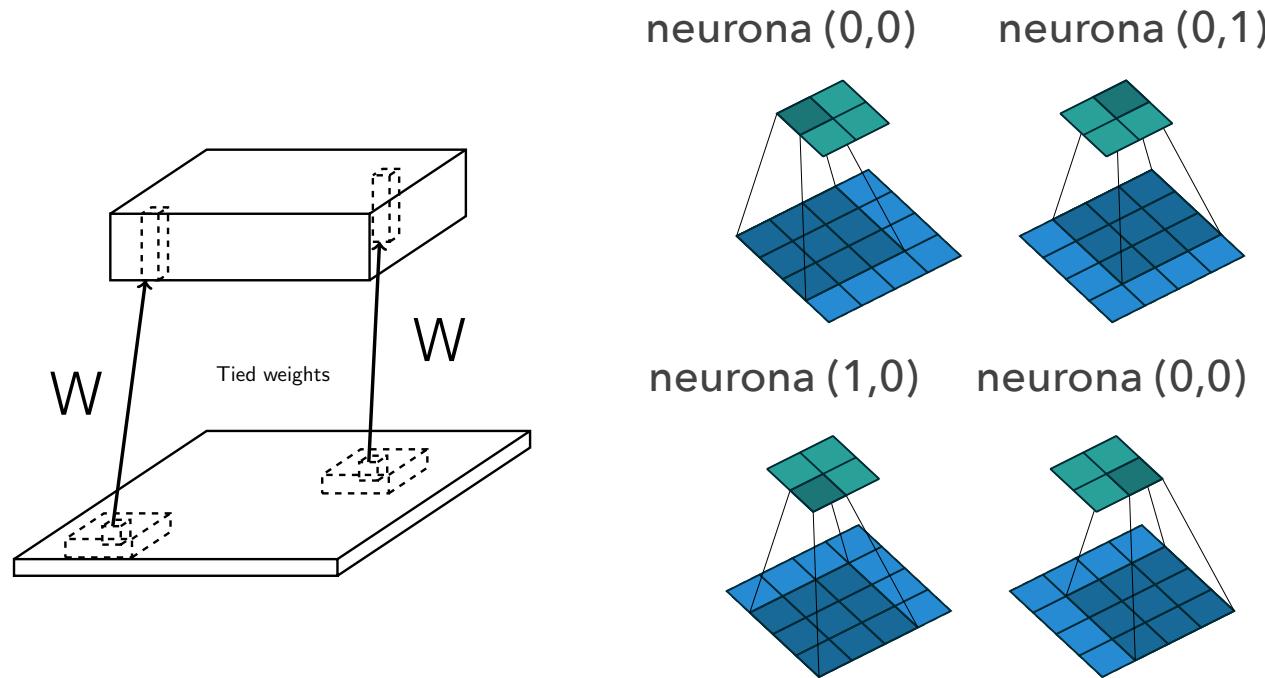
# Mapas 2D

- En el caso bidimensional vale lo mismo: el stride será típicamente unitario en cada dimensión  $K_i = K_j = 1$  y el número de neuronas de cada canal se determinará para poder “barrer” completamente el patrón de entrada.



# Mapas 2D

- Por consistencia con la forma del campo visual, los “pesos” de cada neurona se dispondrán en una **matriz  $W$  de tamaño  $S_I \times S_j$  idéntico al tamaño de campo receptivo**. Por definición, esta matriz será compartida por todo el grupo de neuronas de un filtro o canal.



# Ejemplo

- Consideremos por ejemplo un filtro 2D con campos receptivos de  $3 \times 3$  y strides de  $1 \times 1$ , donde la neurona  $(i, j)$  se "mira" los valores entre las posiciones  $(i, j)$  y  $(i + 2, j + 2)$  del patrón de entrada. Procesaremos un input de  $5 \times 5$  y por lo tanto el canal estará formado por **9 unidades dispuestas en un arreglo de  $3 \times 3$** .

3	3	2	1	0
0	0	1	3	1
3	1	2	2	3
2	0	0	2	2
2	0	0	0	1

Input

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

FM

0	1	2
2	2	0
0	1	2

pesos W

- Asumiremos por simplicidad umbrales de activación 0 y funciones de activación lineales.

# Ejemplo

$3_0$	$3_1$	$2_2$	$1$	$0$
$0_2$	$0_2$	$1_0$	$3$	$1$
$3_0$	$1_1$	$2_2$	$2$	$3$
$2$	$0$	$0$	$2$	$2$
$2$	$0$	$0$	$0$	$1$

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

$3$	$3_0$	$2_1$	$1_2$	$0$
$0$	$0_2$	$1_2$	$3_0$	$1$
$3$	$1_0$	$2_1$	$2_2$	$3$
$2$	$0$	$0$	$2$	$2$
$2$	$0$	$0$	$0$	$1$

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

$3$	$3$	$2_0$	$1_1$	$0_2$
$0$	$0$	$1_2$	$3_2$	$1_0$
$3$	$1$	$2_0$	$2_1$	$3_2$
$2$	$0$	$0$	$2$	$2$
$2$	$0$	$0$	$0$	$1$

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

$3$	$3$	$2$	$1$	$0$
$0_0$	$0_1$	$1_2$	$3$	$1$
$3_2$	$1_2$	$2_0$	$2$	$3$
$2_0$	$0_1$	$0_2$	$2$	$2$
$2$	$0$	$0$	$0$	$1$

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

$3$	$3$	$2$	$1$	$0$
$0$	$0_0$	$1_1$	$3_2$	$1$
$3$	$1_2$	$2_2$	$2_0$	$3$
$2$	$0_0$	$0_1$	$2_2$	$2$
$2$	$0$	$0$	$0$	$1$

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

$3$	$3$	$2$	$1$	$0$
$0$	$0$	$1_0$	$3_1$	$1_2$
$3$	$1$	$2_2$	$2_2$	$3_0$
$2$	$0$	$0_0$	$2_1$	$2_2$
$2$	$0$	$0$	$0$	$1$

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

$3$	$3$	$2$	$1$	$0$
$0$	$0$	$1$	$3$	$1$
$3_0$	$1_1$	$2_2$	$2$	$3$
$2_2$	$0_2$	$0_0$	$2$	$2$
$2_0$	$0_1$	$0_2$	$0$	$1$

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

$3$	$3$	$2$	$1$	$0$
$0$	$0$	$1$	$3$	$1$
$3$	$1_0$	$2_1$	$2_2$	$3$
$2$	$0_2$	$0_2$	$2_0$	$2$
$2$	$0_0$	$0_1$	$0_2$	$1$

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

$3$	$3$	$2$	$1$	$0$
$0$	$0$	$1$	$3$	$1$
$3$	$1$	$2_0$	$2_1$	$3_2$
$2$	$0$	$0_2$	$2_2$	$2_0$
$2$	$0$	$0_0$	$0_1$	$1_2$

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0



# Ejemplo

- Neurona (0,0)

3 <sub>0</sub>	3 <sub>1</sub>	2 <sub>2</sub>	1	0
0 <sub>2</sub>	0 <sub>2</sub>	1 <sub>0</sub>	3	1
3 <sub>0</sub>	1 <sub>1</sub>	2 <sub>2</sub>	2	3
2	0	0	2	2
2	0	0	0	1

0	1	2
2	2	0
0	1	2

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

# Ejemplo

- Neurona (1,0)

3	3	2	1	0
0 <sub>0</sub>	0 <sub>1</sub>	1 <sub>2</sub>	3	1
3 <sub>2</sub>	1 <sub>2</sub>	2 <sub>0</sub>	2	3
2 <sub>0</sub>	0 <sub>1</sub>	0 <sub>2</sub>	2	2
2	0	0	0	1

0	1	2
2	2	0
0	1	2

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

# Ejemplo

- Neurona (2,0)

3	3	2	1	0
0	0	1	3	1
3 <sub>0</sub>	1 <sub>1</sub>	2 <sub>2</sub>	2	3
2 <sub>2</sub>	0 <sub>2</sub>	0 <sub>0</sub>	2	2
2 <sub>0</sub>	0 <sub>1</sub>	0 <sub>2</sub>	0	1

0	1	2
2	2	0
0	1	2

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

# Ejemplo

- Neurona (0,1)

3	3 <sub>0</sub>	2 <sub>1</sub>	1 <sub>2</sub>	0
0	0 <sub>2</sub>	1 <sub>2</sub>	3 <sub>0</sub>	1
3	1 <sub>0</sub>	2 <sub>1</sub>	2 <sub>2</sub>	3
2	0	0	2	2
2	0	0	0	1

0	1	2
2	2	0
0	1	2

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

# Ejemplo

$3_0$	$3_1$	$2_2$	$1$	$0$
$0_2$	$0_2$	$1_0$	$3$	$1$
$3_0$	$1_1$	$2_2$	$2$	$3$
$2$	$0$	$0$	$2$	$2$
$2$	$0$	$0$	$0$	$1$

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

$3$	$3_0$	$2_1$	$1_2$	$0$
$0$	$0_2$	$1_2$	$3_0$	$1$
$3$	$1_0$	$2_1$	$2_2$	$3$
$2$	$0$	$0$	$2$	$2$
$2$	$0$	$0$	$0$	$1$

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

$3$	$3$	$2_0$	$1_1$	$0_2$
$0$	$0$	$1_2$	$3_2$	$1_0$
$3$	$1$	$2_0$	$2_1$	$3_2$
$2$	$0$	$0$	$2$	$2$
$2$	$0$	$0$	$0$	$1$

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

$3$	$3$	$2$	$1$	$0$
$0_0$	$0_1$	$1_2$	$3$	$1$
$3_2$	$1_2$	$2_0$	$2$	$3$
$2_0$	$0_1$	$0_2$	$2$	$2$
$2$	$0$	$0$	$0$	$1$

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

$3$	$3$	$2$	$1$	$0$
$0$	$0_0$	$1_1$	$3_2$	$1$
$3$	$1_2$	$2_2$	$2_0$	$3$
$2$	$0_0$	$0_1$	$2_2$	$2$
$2$	$0$	$0$	$0$	$1$

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

$3$	$3$	$2$	$1$	$0$
$0$	$0$	$1_0$	$3_1$	$1_2$
$3$	$1$	$2_2$	$2_2$	$3_0$
$2$	$0$	$0_0$	$2_1$	$2_2$
$2$	$0$	$0$	$0$	$1$

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

$3$	$3$	$2$	$1$	$0$
$0$	$0$	$1$	$3$	$1$
$3_0$	$1_1$	$2_2$	$2$	$3$
$2_2$	$0_2$	$0_0$	$2$	$2$
$2_0$	$0_1$	$0_2$	$0$	$1$

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

$3$	$3$	$2$	$1$	$0$
$0$	$0$	$1$	$3$	$1$
$3$	$1_0$	$2_1$	$2_2$	$3$
$2$	$0_2$	$0_2$	$2_0$	$2$
$2$	$0_0$	$0_1$	$0_2$	$1$

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

$3$	$3$	$2$	$1$	$0$
$0$	$0$	$1$	$3$	$1$
$3$	$1$	$2_0$	$2_1$	$3_2$
$2$	$0$	$0_2$	$2_2$	$2_0$
$2$	$0$	$0_0$	$0_1$	$1_2$

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

# Entonces ...

- Una red convolucional (CNN) se construye sobre 3 ideas fundamentales: conectividad limitada, compartición de pesos y agresiva reducción de dimensionalidad vía pooling.
- La compartición de pesos permite ahorrar aún más parámetros dándonos la oportunidad de usar más unidades y campos receptivos con un buen grado de redundancia (overlap).
- Un grupo de neuronas con pesos compartidos se denominará canal ó filtro y al ser aplicado a volumen de entrada producirá como resultado un mapa de características consistente con la dimensionalidad de la capa.
- En el caso 2D las neuronas de un canal se organizan sobre un arreglo 2D. Sus pesos corresponden a un arreglo 2D (matriz) que tiene la forma del campo receptivo donde se aplicará.
- El número de neuronas de un canal se deduce del tamaño del tamaño del filtro y del stride.

